

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Nama : Ilham Bintang Sebastian

NIM 224308058

Kelas : TKA 7C

Akun Github (Tautan) : <https://github.com/ilhambintang>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

- Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Deep Reinforcement Learning (DRL) adalah evolusi dari Reinforcement Learning (RL) yang memanfaatkan jaringan saraf untuk menangani situasi yang rumit dan berkelanjutan. Dalam RL, agen belajar dengan berinteraksi dengan lingkungannya untuk mendapatkan imbalan tertinggi, sementara pada DRL, proses belajar dilakukan dengan memanfaatkan kemampuan Deep Learning untuk mengenali pola dan memprediksi nilai tindakan dengan lebih efektif. Salah satu algoritma penting dalam DRL adalah Deep Q-Network (DQN). DQN menggantikan tabel Q tradisional dengan menggunakan jaringan saraf untuk memperkirakan nilai Q dari setiap tindakan berdasarkan kondisi lingkungan yang ada. Algoritma ini menerapkan konsep experience replay untuk meningkatkan kestabilan pembelajaran serta strategi epsilon-greedy untuk menyeimbangkan antara eksplorasi dan eksploitasi. DQN banyak diterapkan dalam sistem kontrol yang kompleks seperti robot otonom, mobil tanpa pengemudi, dan optimasi energi, karena mampu beradaptasi dengan perubahan lingkungan tanpa membutuhkan model matematis yang jelas dari sistem.

dan strategi *epsilon-greedy* untuk menyeimbangkan eksplorasi dan eksploitasi DQN banyak digunakan dalam sistem kontrol kompleks seperti robot otonom, kendaraan tanpa pengemudi, dan optimasi energi karena mampu beradaptasi terhadap perubahan lingkungan tanpa memerlukan model matematis sistem yang eksplisit.

4. Diskusi

Deep Q-Network (DQN) memiliki beberapa keuntungan dibandingkan metode Q-Learning tradisional, terutama dalam menangani sistem yang rumit dan ruang keadaan yang luas. Pada Q-Learning biasa, pembelajaran dilakukan melalui penggunaan tabel Q (Q-Table), yang mencakup nilai untuk setiap kombinasi keadaan dan aksi. Metode ini berhasil untuk sistem sederhana dengan jumlah keadaan yang terbatas, namun menjadi kurang efisien ketika ruang keadaannya sangat besar atau kontinu. DQN mengatasi batasan ini dengan memanfaatkan jaringan saraf tiruan (Neural Network) untuk memperkirakan nilai Q secara langsung, sehingga dapat beroperasi dalam lingkungan yang lebih rumit dan berubah-ubah. Selain itu, DQN juga memiliki fitur experience replay yang memungkinkan pengambilan sampel pengalaman secara acak selama pelatihan. Metode ini membantu mengurangi hubungan antara data dan meningkatkan kestabilan pembelajaran. Strategi *epsilon-greedy* yang digunakan dalam DQN juga berperan dalam menjaga keseimbangan antara eksplorasi dan eksploitasi, yang memungkinkan agen belajar lebih efektif dari lingkungannya. Untuk mengadaptasi DQN pada kontrol sistem dinamis seperti drone atau robot industri, beberapa penyesuaian diperlukan agar algoritma dapat berfungsi dengan baik dalam lingkungan yang terus berubah. Dalam aplikasi di dunia nyata, DQN sering dipadukan dengan metode kontrol tradisional seperti PID atau Fuzzy Logic untuk memastikan kestabilan sistem saat model masih beradaptasi. Agar sistem dapat belajar dengan baik, fungsi reward harus dirancang dengan hati-hati sesuai dengan tujuan kontrol, seperti menjaga keseimbangan drone atau mengarahkan robot dengan efisien ke posisi target. Melalui kombinasi rancangan yang tepat, DQN dapat beradaptasi secara mandiri terhadap perubahan lingkungan dan memberikan kontrol yang akurat pada sistem dinamis yang kompleks.




5. Assignment

Dalam tugas minggu kelima ini dikembangkan sistem pengenalan gestur tangan real-time menggunakan Support Vector Machine (SVM) dan MediaPipe yang

terintegrasi dengan OpenCV. Proses dimulai dengan memuat dataset keypoint tangan menggunakan `pd.read_csv()`, kemudian menyesuaikan nama kolom agar seragam. Dataset diasumsikan memiliki label pada kolom pertama dan noise pada kolom terakhir, sehingga fitur (X) diambil dari kolom ke-2 hingga sebelum kolom terakhir, sedangkan label (y) berasal dari kolom pertama. Data dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian menggunakan `train_test_split()`. Model SVM dengan kernel linear dilatih menggunakan `SVC(kernel='linear')` dan diuji pada data uji untuk menghitung tingkat akurasi melalui `accuracy_score()`. Setelah pelatihan, model diterapkan dalam deteksi gestur tangan secara real-time dengan MediaPipe dan OpenCV. Kamera menangkap citra, mengonversinya ke format RGB, lalu mendeteksi landmark tangan menggunakan `hands.process()`. Jika tangan terdeteksi, koordinat x, y, dan z setiap titik diekstraksi dan dimasukkan ke model SVM untuk memprediksi gestur. Hasil prediksi ditampilkan di layar menggunakan `cv2.putText()`. Dengan menggabungkan MediaPipe untuk pelacakan titik kunci tangan dan SVM untuk klasifikasi gestur, sistem ini mampu mengenali posisi serta gerakan tangan secara akurat dalam waktu nyata, menunjukkan penerapan efektif antara *machine learning* dan *computer vision* dalam analisis gerakan manusia.

6. Data dan Output Hasil Pengamatan

Tabel berikut menunjukkan hasil pengamatan deteksi gerakan tangan menggunakan sistem berbasis MediaPipe. Setiap gerakan dianalisis berdasarkan jumlah tangan yang terdeteksi, jumlah titik sendi per tangan, posisi atau titik penting pada tangan, serta keterangan visualisasi output yang dihasilkan.

No	Dokumentasi	Deteksi	Jumlah Titik Sendi per Tangan	Posisi/Titik Penting	Keterangan Output Visual
1		Gerakan Tangan terbuka lebar Jumlah Tangan Terdeteksi 2	21 titik per tangan	Semua Jari terbuka, jari-jari terlihat Jelas	Garis hijau menghubungkan sendi, titik merah di setiap sendi
2		Gerakan Tangan membentuk "peace" Jumlah Tangan Terdeteksi 1	21 titik	Jari telunjuk & jari Tengah terangkat, jari Lain menekuk	Garis hijau mengikuti bentuk jari, visualisasi sendi tetap akurat
3		Gerakan Tangan terbuka normal Jumlah Tangan Terdeteksi 1	21 titik	Semua Jari terbuka, Posisi natural	Deteksi sendi stabil, tidak ada tangan kedua

7. Kesimpulan

Berdasarkan pengujian dan analisis yang telah dilakukan, dapat ditarik kesimpulan bahwa program yang dibuat berhasil melakukan pengenalan gestur tangan secara langsung dengan menggunakan kombinasi model SVM dan MediaPipe. Tingkat keakuratan model sangat bergantung pada kualitas kumpulan data serta parameter yang diimplementasikan, sehingga optimasi melalui perbaikan kumpulan data, penyesuaian model, dan peningkatan performa dalam waktu nyata dapat meningkatkan hasil pengenalan. Sistem ini mampu mengidentifikasi gerakan tangan dengan cukup efektif, meskipun masih menghadapi kendala terkait gangguan suara dan kondisi pencahayaan. Penting untuk dicatat bahwa sistem hanya mampu mendeteksi keberadaan tangan dan maksimal dua tangan secara

bersamaan, sehingga tidak dapat mengenali objek lain atau lebih dari dua tangan dalam waktu yang sama.

8. Saran

Berikut adalah beberapa saran perbaikan yang dapat dilakukan untuk meningkatkan akurasi serta kinerja sistem.

1. Penambahan Dataset: Meningkatkan jumlah dan variasi sampel untuk mencakup beragam kondisi pencahayaan serta posisi tangan, sehingga model menjadi lebih umum dan tepat.

2. Optimasi Model dan Kinerja Real-Time: Melakukan penyesuaian hyperparameter pada SVM (seperti C dan gamma), optimasi kode, kompresi gambar, dan post-processing seperti pemulusan waktu untuk membuat prediksi lebih stabil.

10. Daftar Pustaka

Mnih, V., et al. (2015). *Human-level control through deep reinforcement learning*. *Nature*, 518(7540), 529–533.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.